Понятие эталона. Отступы и классификация объектов качества

От основных понятий — к разбору нормального трафика и SYN-flood

Объект, признаки, класс и классификация

Понятие	Что означает
Объект	То, что мы исследуем
Признаки	Измеримые свойства объекта
Класс	Одна из заранее заданных групп
Классификация	Выбор класса по признакам объекта

Чтобы выбрать класс, нужно задать правило

Модель и её обучение

Классификатор, или модель, — правило выбора класса по признакам

Обучение	Применение готовой модели
Объекты + известные классы (метки)	Признаки нового объекта
Подбираем правило по этим примерам	Получаем прогноз класса

Обучающая выборка — набор примеров с известными метками.
Известная метка и прогноз модели могут не совпадать: это ошибка.

Начнём с простого правила — сравнения с образцами классов

Определение эталона класса

Эталон класса — образец этого класса, принятый для сравнения с другими объектами.

Зачем он нужен

Помогает понять, к какому классу ближе исследуемый объект

Как его использовать

Выбрать образец каждого класса и сравнить с ними новый объект

Определение эталона и способ его выбора — разные вопросы

Похожесть измеряем расстоянием

Все объекты описываем одним и тем же набором признаков

Значения двух признаков — координаты точки. Евклидово расстояние — расстояние по прямой между точками после выбора масштаба.

Меньше расстояние

Объекты ближе друг к другу в выбранном описании

Сначала задаём масштаб

Разные единицы и большие числа могут подавить другой признак

Эталоны выбираем и сравниваем в одном масштабе

Выбор эталона: медоид

Один из способов выбрать образец класса

Медоид — объект с наименьшей суммой расстояний до остальных объектов своего класса.

1. Берём кандидата из обучающих объектов класса
2. Складываем расстояния от него до остальных
3. Выбираем кандидата с наименьшей суммой

Повторяем для каждого класса. Проверочные объекты не используем

Правило ближайшего эталона

Шаг	Действие
1. Описать объект	Получить признаки в том же масштабе
2. Сравнить	Посчитать расстояние до каждого эталона
3. Классифицировать	Выбрать класс ближайшего эталона

Если расстояния почти равны, преимущество выбранного класса мало.

Как выразить это преимущество числом?

Отступ: преимущество своего класса

Отступ — разность оценок истинного класса и конкурирующего класса

Оценка показывает, насколько правило предпочитает класс.
Для эталона оценка класса = минус расстояние.

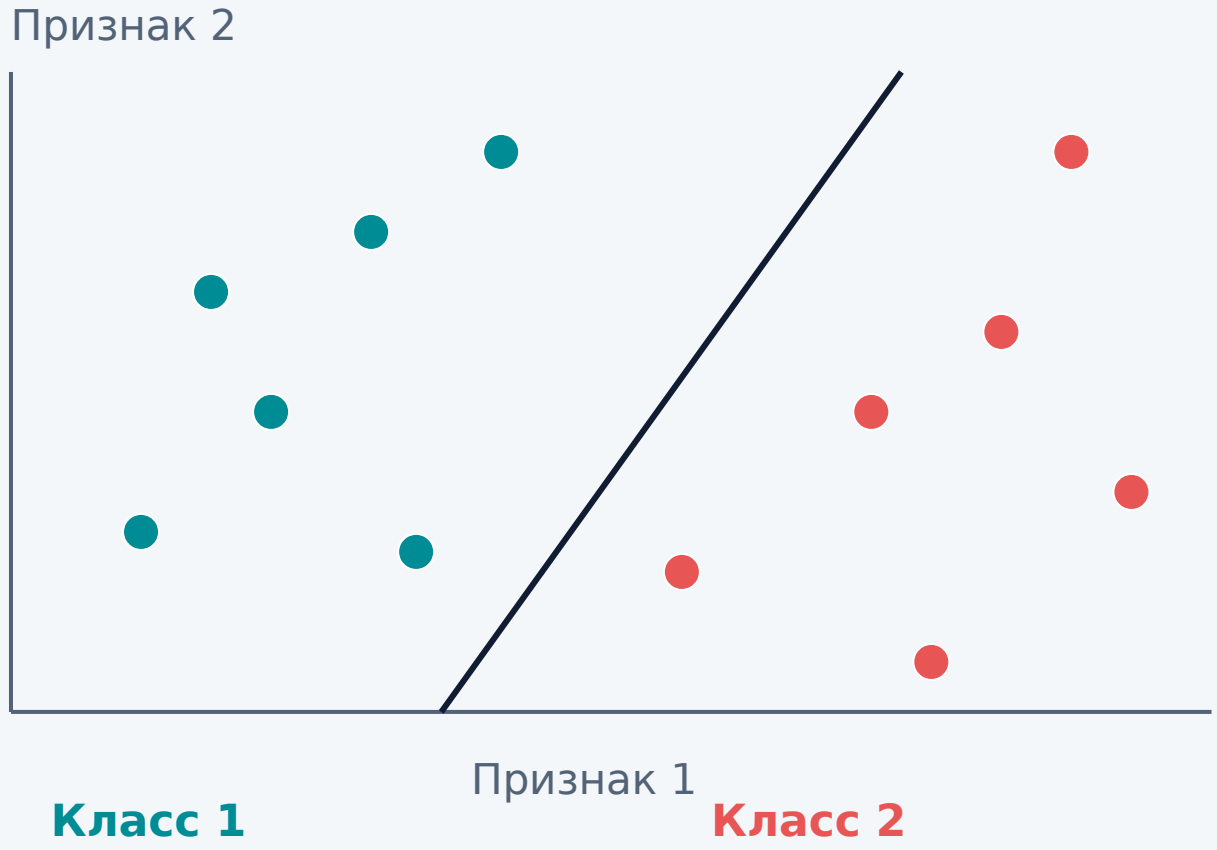
отступ = расстояние до чужого − до своего

Положительный	Нулевой	Отрицательный
Свой класс ближе	Расстояния равны	Чужой класс ближе

Для проверки правильности по знаку нужна истинная метка

SVM: граница по обучающим примерам

SVM — метод опорных векторов. При двух признаках линейная модель строит прямую.



Граница решения

На ней меняется выбираемый класс.

Правило вычисляет число f. Его знак выбирает класс; f = 0 — граница.

SVM обучается на всей выборке, а не на двух эталонах.

Зазор и мягкий зазор SVM

Зазор — полоса вокруг границы, которую SVM стремится сделать широкой

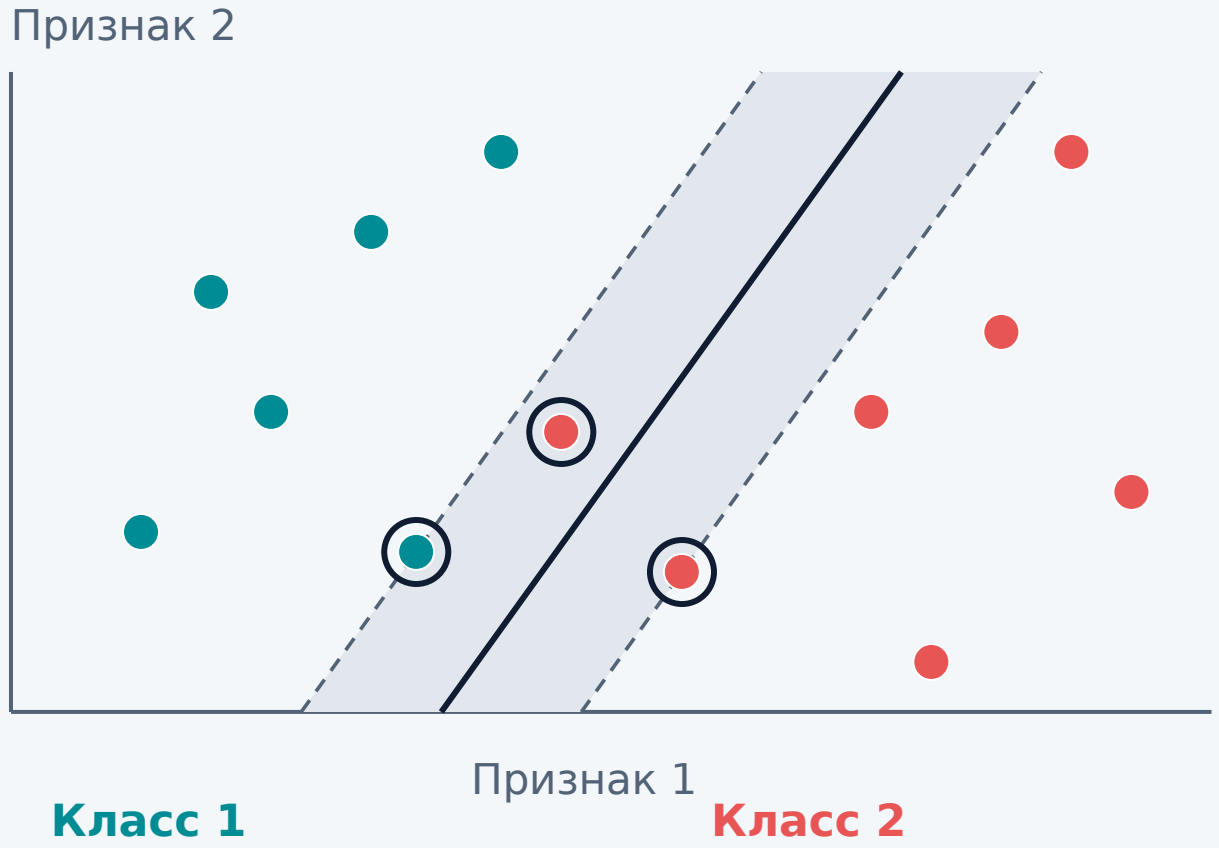


Схема обучения; учебные классы пока обозначены условно.

Мягкий зазор

Допускает объекты внутри полосы и на неверной стороне. За нарушения есть штраф.

C — цена нарушений.

Опорные векторы — примеры, участвующие в определении границы. На схеме — в кольцах.

Геометрический отступ и запас прочности

Для уже обученной линейной модели

Что измеряем	Как читаем
Геометрический отступ γ Расстояние до границы со знаком	+ на правильной стороне − на ошибочной; нужна метка
Расстояние без знака $r = \lvert\gamma\rvert$ Запас сохранения текущего ответа	Как мало нужно изменить признаки, чтобы дойти до границы

Это расстояние в выбранном масштабе, а не вероятность.
Большой запас может сохранять ошибочный ответ.

Отступ для эталонов и геометрический отступ SVM определены по-разному.

Что такое пограничный объект

**Пограничный объект близок к границе: небольшое изменение
признаков может изменить прогноз.**

Зазор SVM	Полоса перепроверки
Участвует в обучении модели	Выделяем у готовых результатов
Компромисс регулируется C	Порог выбираем отдельно

Пограничными бывают оба класса, верные ответы и ошибки

Единый пример: норма и SYN-flood

Классифицируем окна трафика к одному сервису

Обычное TCP-подключение

SYN → SYN-ACK → ACK
Клиент и сервер завершают трёхэтапное рукопожатие.

SYN-flood

Множество начатых подключений не завершается. Занятая очередь может мешать обычным клиентам.

Два класса: нормальный трафик и SYN-flood.
Большое число SYN само по себе ещё не доказывает атаку.

Теперь определим, что именно измеряем в каждом окне

Из трафика получаем признаки

Объект — окно 10 секунд к одному IP и TCP-порту

Признак	Смысл	Масштаб в коде
Входящие SYN/с	Интенсивность начала подключений	÷ 1000
Незавершённые попытки, %	Нет полного рукопожатия за 3 с	÷ 100

20 окон для обучения: 10 нормы + 10 атаки.
8 специально выбранных проверок. Все значения синтетические.

Нужны оба направления трафика. Повторы SYN входят в скорость, но объединяются в одну попытку для доли. Окна без SYN исключаем; ждём 3 с для завершения наблюдения.

Выбираем два эталона трафика

В каждом классе находим медоид среди обучающих окон

Класс	Эталон	SYN/с	Не завершены
Норма	N05	600	15%
SYN-flood	A06	1300	65%

Код складывает расстояния для каждого кандидата.
N05 и A06 дают минимальную сумму в своих классах.

Это образцы нашей выборки, а не универсальные пороги атаки

Окно T07: классификация по эталонам

1200 SYN/с и 16% незавершённых; известный учебный класс — норма

После масштаба: (1,20; 0,16)

До эталона нормы N05	До эталона атаки A06
0,600083	0,500100

Ближе эталон атаки → прогноз «SYN-flood» → ошибка.
Отступ = 0,500100 − 0,600083 ≈ −0,099983

Один образец грубо описал норму при высокой легитимной нагрузке

Обучаем SVM на той же выборке

SVC — реализация алгоритма SVM в библиотеке scikit-learn

```
model = SVC(kernel="linear", C=1,
            tol=1e-10, shrinking=False)
model.fit(X_train, y_train)
```

X_train — признаки всех 20 обучающих окон.
y_train — их известные метки: норма = −1, атака = +1.

Масштаб тот же. Теперь проверим неизменённое окно T07

То же окно T07: результат SVM

1200 SYN/с и 16% → прогноз «норма»; в этом примере ответ верный

Число правила f	Отступ со знаком γ	Запас r
−0,248833	+0,101921	0,101921

```
f = model.decision_function(X_check)
r = np.abs(f) / np.linalg.norm(model.coef_)
gamma = y_check * f / np.linalg.norm(model.coef_)
```

T07 — одно из X_check. Запас измерен в масштабе признаков.
Исправление одного случая не доказывает превосходство SVM.

Считаем отступы для восьми окон

Известная метка нужна для знака γ; r — неотрицательное расстояние

ID	Истинный класс	Прогноз SVM	Отступ γ	Запас r
T01	Норма	Норма	0,551	0,551
T02	Атака	Атака	0,697	0,697
T03	Норма	Норма	0,018	0,018
T04	Атака	Норма	−0,043	0,043
T05	Норма	Атака	−0,024	0,024
T06	Атака	Атака	0,034	0,034
T07	Норма	Норма	0,102	0,102
T08	Атака	Атака	0,285	0,285

γ < 0 — ошибка: T04 и T05. Остальные γ > 0. Во всех строках r = |γ|.

Пограничные окна и две ошибки

Для демонстрации выбираем перепроверку при r < 0,10

Малый запас: T03, T04, T05, T06

T04 · пропуск атаки

Была атака → прогноз «норма».
Можно пропустить угрозу доступности сервиса.

T05 · ложная тревога

Была норма → прогноз «атака».
Реакция может помешать легитимным клиентам.

Обе ошибки здесь пограничные. В реальной сети так бывает не всегда. Порог 0,10 — правило перепроверки; это не зазор обучения SVM.

Как использовать результат в ИБ

triage — учебная функция первичной сортировки; SOC — команда мониторинга ИБ

Ввод: SYN/с; %	Прогноз	Сигнал атаки	Перепроверка
900; 40%	Норма	Нет	Да
1550; 88%	Атака	Да	Нет

Сигнал атаки: прогноз «атака» при любом запасе.
Перепроверка: малый запас при любом прогнозе.

Аналитик проверяет логи, доступность, очередь соединений и потери.
Перед внедрением: реальные данные, отдельная проверка во времени, оценка пропусков и ложных тревог. Учебный код не блокирует трафик.

Что показал сквозной пример

Понятие	Что получили в одном примере
Эталон	N05 и A06 выбраны как медоиды своих классов
Классификация	T07 прошёл сравнение с эталонами, затем SVM
Отступы	Рассчитаны все 8 окон; малый запас у T03–T06
Польза для ИБ	Прогноз и запас помогают назначить проверку

Запас объясняет устойчивость ответа, но не гарантирует его правильность

Источники

Первоисточники и официальные документы; ссылки активны

[1] Cortes & Vapnik (1995)

Support-vector networks

[2] Stanford CS229, A. Ng

Functional / geometric margin; soft margin

[3] Schubert & Rousseeuw (2019)

Faster k-Medoids Clustering

[4] Eddy (2007), RFC 4987

TCP SYN Flooding Attacks and Common Mitigations

[5] scikit-learn: документация

SVC, decision_function, масштабирование

[6] Moosavi-Dezfooli et al. (CVPR 2016)

DeepFool: расстояние до границы

[7] UNB / CICDDoS2019

Данные для следующего этапа проверки

[8] NIST SP 800-94

Проверка сигналов IDS и работа с ошибками