ТЕМА 1.13 · ТЕКСТ ВЫСТУПЛЕНИЯ

Понятие эталона. Отступы и классификация объектов качества

13 слайдов · 13 минут · единый пример SYN-flood

СЛАЙД 01 · 20 с

Понятие эталона. Отступы и классификация объектов качества

Разберём, как программа выбирает класс объекта и как объяснить её ответ. Сначала определим основные понятия. Затем на одном примере сравним обычный трафик с SYN-flood, найдём ошибки модели и посмотрим, какие результаты стоит перепроверить.

СЛАЙД 02 · 70 с

Как модель выбирает класс

Объектом называем то, что исследуем. Признаки описывают его через измеримые свойства. Для программы это набор значений, одинаковый по составу у всех объектов. При двух признаках значения можно изобразить координатами точки. Классом называем одну из заданных групп, а классификацией выбор группы по признакам. Чтобы получить ответ, нужно правило. Его называют классификатором, или моделью. Правило можно подобрать по обучающей выборке. Это примеры с уже известными правильными классами, которые называют метками. Обучение означает настройку правила по этим примерам. Потом модель применяют к другим объектам. При работе с новым наблюдением она не получает правильную метку. Метку используют позже, когда проверяют прогноз. Прогноз и известная метка могут различаться, потому что модель способна ошибиться. Поэтому в проверках будем показывать оба ответа: что задано в данных и что выбрала программа.

СЛАЙД 03 · 65 с

Эталон класса и его выбор

Эталоном класса называем образец, который приняли для сравнения с другими объектами. У каждого класса будет свой образец. Похожесть измеряем расстоянием между точками. Сначала выбираем масштаб признаков, иначе большие числа могут почти полностью определять расстояние. Близость означает сходство только по выбранным признакам. Другие свойства объекта здесь не учитываются. Затем используем евклидово расстояние, то есть длину прямого отрезка между точками. Для выбора эталона возьмём медоид. Это объект с наименьшей суммой расстояний до остальных объектов своего класса. Перебираем кандидатов, складываем расстояния и выбираем наименьшую сумму. Для каждого класса делаем это отдельно и используем только обучающие примеры. При таком выборе эталон совпадает с одним из существующих объектов. Само определение эталона шире: медоид является нашим конкретным способом найти образец.

СЛАЙД 04 · 60 с

Ближайший эталон и отступ

Когда образцы выбраны, считаем расстояние от нового объекта до каждого эталона. Выбираем класс ближайшего. Если расстояния почти равны, преимущество небольшое. Даже при правильном ответе близкие расстояния показывают, что один класс совсем немного опережает другой. Отступ сравнивает оценку правильного класса с оценкой другого: из первой вычитаем вторую. Для эталонов оценкой берём минус расстояние, поэтому отступ равен чужому расстоянию минус своё. При положительном результате выбран правильный класс, при отрицательном чужой. Ноль означает равенство оценок. Назвать класс своим можем только по известной метке. У нового неразмеченного объекта расстояния доступны, но проверить правильность по знаку пока нельзя. Один образец может плохо описывать разнообразие целого класса. Поэтому дальше построим другое правило, которое использует всю обучающую выборку.

СЛАЙД 05 · 70 с

SVM с мягким зазором

SVM, или машина опорных векторов, обучает такое правило. При двух признаках линейная SVM строит прямую, разделяющую области выбора классов. Это граница решения. SVM стремится оставить вокруг границы широкую полосу, называемую зазором. Мягкий зазор допускает отдельные обучающие точки внутри полосы и даже на неверной стороне. За нарушения назначается штраф, а C определяет их цену. Точка внутри полосы может быть классифицирована правильно, поэтому нарушение зазора не всегда означает ошибку. Опорными векторами называют обучающие объекты, участвующие в определении границы. Они выполняют другую роль, чем эталоны, которые служат образцами классов. Опорных точек может быть несколько в каждом классе. Их число и положение определяются обучением, а не выбором типичного образца.

СЛАЙД 06 · 65 с

Отступ и запас прочности решения

Модель вычисляет число f и по его знаку выбирает класс. При нуле точка находится на границе. После обучения измеряем расстояние до готовой границы. Геометрический отступ γ показывает его со знаком: плюс при правильном ответе, минус при ошибке. Для этого нужна известная метка. Модуль γ даёт расстояние r без знака. Его можно вычислить и для нового объекта. Для линейной модели r показывает кратчайший путь точки до границы в выбранном масштабе. Изменение признаков меньшей длины границу не пересечёт. Это и называем запасом прочности решения. Большое расстояние не доказывает правильность и не является вероятностью. Модель может ошибиться далеко от линии. Тогда небольшие изменения сохранят именно этот ошибочный ответ. Малое расстояние выделяет пограничные случаи. Для их перепроверки после обучения выбирают отдельный порог. Этот порог не следует из C и не равен зазору SVM. Теперь применим понятия к трафику.

СЛАЙД 07 · 80 с

SYN-flood: что измеряем

TCP-соединение начинается с трёх сообщений: SYN от клиента, SYN-ACK от сервера и завершающий ACK от клиента. При SYN-flood множество начатых подключений не завершается. Очередь может занять ресурсы и помешать обычным пользователям. Большое число SYN бывает и при обычном наплыве клиентов, а потери сети мешают завершению соединений. Одним объектом считаем десять секунд трафика к одному IP-адресу и TCP-порту. Берём среднее число входящих SYN в секунду и процент попыток, не завершивших рукопожатие за три секунды. Для скорости учитываем повторы, а при подсчёте попыток объединяем их. Нужны оба направления обмена; окна без SYN исключаем. Последним попыткам даём время завершиться, поэтому измерение приходит с задержкой. В расчётах скорость делим на тысячу, проценты на сто. Все данные учебные: двадцать обучающих окон, поровну нормы и атаки, и восемь специально выбранных проверок.

СЛАЙД 08 · 50 с

Два эталона и модель SVM

Для нормы медоидом стал N05: 600 SYN в секунду и 15 процентов незавершённых попыток. Для атаки выбран A06: 1300 SYN и 65 процентов. Код проверяет суммы расстояний всех кандидатов. Его и исходные строки можно открыть в Google Colab. Эти числа описывают нашу таблицу и не являются универсальными порогами атаки. Затем на всех двадцати окнах обучаем линейную SVM с C, равным единице. В scikit-learn её реализует класс SVC. Одна команда создаёт модель, следующая запускает обучение. Норму обозначаем минус единицей, атаку плюс единицей. Эталоны остаются для первого способа сравнения, а SVM использует всю выборку.

СЛАЙД 09 · 90 с

Одно T07, два способа классификации

В T07 приходит 1200 SYN в секунду, незавершённость составляет 16 процентов. По условию это нормальный трафик. После масштабирования получаем 1,20 и 0,16. До нормального эталона расстояние около 0,600, до атакующего около 0,500. Ближе оказалась атака. Для известного нормального класса отступ равен 0,500 минус 0,600, то есть примерно минус 0,100. Правило эталонов ошиблось. Высокая обычная нагрузка сделала окно похожим на образец атаки. Мы не меняли ни измерения T07, ни правильную метку. Другим стало только правило выбора класса. Теперь подаём те же измерения SVM. Она выбирает норму, что совпадает с условием. Оценка f около минус 0,249, а геометрический отступ γ около плюс 0,102. Знак f выбирает класс, знак γ показывает правильность по известной метке. Расстояние r тоже около 0,102. Отступ эталонов и отступ SVM вычислены по-разному, поэтому напрямую их значения не сравниваем. Один исправленный пример ещё не доказывает, что SVM всегда лучше.

СЛАЙД 10 · 40 с

Результаты всех восьми проверок

Повторим расчёт для всех восьми проверочных окон. Сначала сравним класс в данных с прогнозом SVM. Ошибки находятся в строках T04 и T05, поэтому их γ отрицательны. У остальных отступ положительный. Расстояние r во всех строках неотрицательное: по нему видна близость к границе, но не правильность. Эти восемь примеров специально подобраны для объяснения. По ним нельзя заявлять точность готового сетевого детектора. Таблица позволяет проверить каждый расчёт и найти строки, которые стоит обсудить подробнее. Посмотрим на те же результаты на рисунке.

СЛАЙД 11 · 85 с

Те же результаты на графике

По горизонтали читаем входящие SYN в секунду, по вертикали процент незавершённых попыток. Каждая точка взята из предыдущей таблицы. Оси подписаны в исходных единицах, а расстояния рассчитаны после того же масштабирования, что и при обучении. Бирюзовый цвет означает известную норму, красный атаку. Чёрная линия показывает границу SVM. Выше неё модель выбирает атаку, ниже норму. Поэтому сразу заметны ошибки. Красная T04 оказалась ниже линии: модель пропустила атаку. Бирюзовая T05 стоит выше линии: обычный трафик вызвал ложную тревогу. T07 находится на стороне нормы и распознано правильно. Серая полоса выделяет расстояния меньше 0,10. В неё попали T03, T04, T05 и T06. T07 с расстоянием около 0,102 находится чуть за пределами полосы, но тоже близко к границе. В этом примере обе ошибки попали в перепроверку. На реальных данных такое совпадение не гарантировано. Полоса помогает выбрать чувствительные к изменению признаков ответы, но не находит все возможные ошибки.

СЛАЙД 12 · 75 с

Как результат помогает аналитику ИБ

Передадим аналитику два отдельных сигнала. attack_alert включается при прогнозе атаки, независимо от расстояния. boundary_review включается при малом расстоянии, независимо от выбранного класса. Учебная функция triage при 900 SYN и 40 процентах отвечает «норма», но просит перепроверку. При 1550 SYN и 88 процентах сообщает об атаке, хотя окно вне серой полосы. Отсутствие пограничности не отменяет этот сигнал. У нового трафика нет готовой метки, поэтому сигнал модели ещё нужно подтвердить. SOC, команда мониторинга и реагирования ИБ, проверяет журналы, доступность, очередь подключений, потери и обычную нагрузку. Модель сама не блокирует трафик. Для внедрения нужны реальные данные, проверка на отдельно выделенных более поздних наблюдениях и оценка пропусков и ложных тревог. Эталоны помогают сравнивать, отступ объясняет близость к границе, а окончательный вывод требует контекста.

СЛАЙД 13 · 10 с

Источники

Определения и методы опираются на эти восемь источников. Учебные данные, расчёты и графики доступны в ноутбуке Google Colab.

01 Support-vector networks

C. Cortes, V. Vapnik. Machine Learning, 1995.

doi.org/10.1007/BF00994018

02 CS229: Support Vector Machines

Stanford University. Конспект лекций.

see.stanford.edu · PDF

03 Faster k-Medoids Clustering: Improving the PAM, CLARA, and CLARANS Algorithms

E. Schubert, P. J. Rousseeuw. 2018; редакция 2019.

arxiv.org/abs/1810.05691

04 RFC 4987. TCP SYN Flooding Attacks and Common Mitigations

W. Eddy. IETF, 2007.

rfc-editor.org · RFC 4987

05 Support Vector Machines — scikit-learn

Официальная документация: линейные SVM, мягкий зазор и параметр C.

scikit-learn.org · документация

06 DeepFool: A Simple and Accurate Method to Fool Deep Neural Networks

S.-M. Moosavi-Dezfooli, A. Fawzi, P. Frossard. CVPR, 2016.

cv-foundation.org · публикация PDF

07 CICDDoS2019

Canadian Institute for Cybersecurity, University of New Brunswick. Страница датасета.

unb.ca/cic · CICDDoS2019

08 NIST SP 800-94. Guide to Intrusion Detection and Prevention Systems (IDPS)

K. Scarfone, P. Mell. NIST, 2007.

csrc.nist.gov · SP 800-94