ТЕМА 1.13 · ТЕКСТ ВЫСТУПЛЕНИЯ

Понятие эталона. Отступы и классификация объектов качества

23 слайда · 15–20 минут и короткое демо · единый пример SYN-flood

---

СЛАЙД 01

Понятие эталона. Отступы и классификация объектов качества

Тема работы — «Понятие эталона. Отступы и классификация объектов качества». Чтобы разобраться в ней без специальной подготовки по машинному обучению, сначала последовательно определим основные понятия. Начнём с объекта и его описания, затем введём эталон, правило классификации и отступ. После всей теории разберём одну задачу информационной безопасности: различение нормального трафика и SYN-flood. Проследим путь от измерений до решения модели, а затем до действий аналитика. Числа и код доступны в ноутбуке Google Colab. Начальная точка любого такого метода — понимание того, что именно исследуется и к какой группе это нужно отнести.

СЛАЙД 02

Объект, признаки, класс и классификация

Объект — то, что мы исследуем. Чтобы с объектом могла работать программа, его описывают признаками: измеримыми свойствами, которые можно записать как набор значений. Важно, чтобы для разных объектов использовался один и тот же набор признаков. Класс — одна из заранее заданных групп, к которой нужно отнести объект. Классификация — выбор класса на основе признаков. Это четыре разные роли: объект существует в исследуемой задаче, признаки дают его описание, классы задают возможные ответы, а классификация выполняет выбор ответа. Сам набор чисел ещё ничего не классифицирует. Для выбора необходимо определить правило, связывающее описание объекта с классом.

СЛАЙД 03

Модель и её обучение

Такое правило называют классификатором, или моделью. На вход модель получает признаки, на выходе сообщает выбранный класс. Обучающая выборка — набор объектов, для которых классы заранее известны. Эти известные ответы называют метками. Обучение означает подбор правила по таким примерам, чтобы оно могло классифицировать и другие объекты. При этом известная метка и прогноз модели — разные вещи. Метка задаёт правильный ответ в размеченной выборке, а прогноз является результатом работы правила и может оказаться ошибочным. Поэтому одного факта обучения недостаточно для доверия каждому ответу. Начнём с простого варианта модели: сравнения исследуемого объекта с образцами классов.

СЛАЙД 04

Определение эталона класса

Эталон класса — образец этого класса, принятый для сравнения с другими объектами. Для каждого класса выбирают свой образец. Если новое наблюдение похоже на определённый эталон, это даёт основание отнести его к соответствующему классу. Сначала важно понять именно роль эталона: он служит точкой сравнения. Конкретный алгоритм выбора образца — уже отдельный вопрос. Определение эталона само по себе ещё не требует выбирать самый центральный объект или обязательно брать существующий пример. В нашей работе будет выбран определённый способ, но до него нужно решить, что означает «похож». Для программы это должна быть заданная численная мера.

СЛАЙД 05

Похожесть измеряем расстоянием

Похожесть будем оценивать расстоянием между описаниями объектов. Чем меньше расстояние, тем ближе объекты в выбранной метрике. Метрика — правило вычисления расстояния. Значения двух признаков — координаты точки. Здесь используем евклидово расстояние: длину прямого отрезка между точками после приведения признаков к выбранному масштабу. Важен масштаб координат. Если значения одного признака численно намного больше другого, первый может определять почти всё расстояние, даже если второй тоже содержательно важен. Поэтому заранее выбирают согласованный масштаб признаков. Он становится частью метода: при его изменении могут измениться расстояния и решения. В выбранном масштабе можно не только сравнивать объекты, но и искать образец, представляющий свой класс.

СЛАЙД 06

Выбор эталона: медоид

Для выбора эталона используем медоид. Медоид — объект с наименьшей суммой расстояний до остальных объектов своего класса. Алгоритм понятен без сложной формулы: берём первого кандидата, складываем расстояния от него до всех остальных; повторяем для каждого кандидата и выбираем наименьшую сумму. Затем независимо делаем то же для другого класса. Используем только обучающие объекты, чтобы проверочные примеры не влияли на построение правила. Полученные эталоны совпадут с существующими объектами: это свойство выбранного метода, а не обязательная часть общего определения эталона. Теперь у каждого класса есть образец, и можно полностью описать правило выбора класса нового объекта.

СЛАЙД 07

Правило ближайшего эталона

Правило ближайшего эталона работает следующим образом. Для нового объекта вычисляем расстояние до образца каждого класса. Сравниваем эти расстояния и выбираем класс ближайшего образца. Это уже полноценный классификатор: у него есть входные признаки и однозначно описанный способ получения ответа, кроме случая точного равенства, для которого нужно отдельное правило. Но одинаковый выбранный класс ещё не означает одинаковое преимущество. В одном случае свой образец может быть значительно ближе, в другом расстояния почти совпадают. Поэтому полезно сохранять не только ответ, но и численную характеристику преимущества одного класса над другим. Так мы приходим к понятию отступа.

СЛАЙД 08

Отступ: преимущество своего класса

Отступ — разность оценок истинного класса и конкурирующего класса. Оценка показывает, насколько правило предпочитает соответствующий класс. Дальше рассматриваем два класса, поэтому конкурент только один. В правиле ближайшего эталона меньшему расстоянию соответствует лучшее предпочтение. Оценка класса здесь равна минус расстоянию до его эталона. Поэтому отступ вычисляем так: расстояние до чужого эталона минус расстояние до своего. Положительное значение означает, что свой эталон ближе и ответ верный. Отрицательное означает выбор чужого класса, ноль — равенство оценок. Чтобы назвать класс своим и оценить правильность по знаку, нужна истинная метка объекта. Однако один образец может грубо описывать разнообразие класса. Альтернативный подход — обучить разделяющую границу по всей выборке.

СЛАЙД 09

SVM: граница по обучающим примерам

SVM, или машина опорных векторов, — алгоритм обучения классификатора. Линейная SVM при двух признаках строит прямую, разделяющую плоскость на области выбора классов. Граница решения — положения, при пересечении которых меняется выбираемый класс. Число f — результат вычисления линейного правила: его знак выбирает класс, а f=0 задаёт границу. Это другой способ построения правила: SVM рассматривает всю обучающую выборку, а не только два эталона. Эталоны остаются отдельным способом сравнения объектов; их нельзя считать заменой данных для обучения SVM. После обучения положение прямой фиксируется, и новое наблюдение получает класс по тому, с какой стороны оно оказалось. Но между примерами можно провести разные границы. Чтобы выбрать одну, SVM учитывает расположение ближайших обучающих объектов.

СЛАЙД 10

Зазор и мягкий зазор SVM

Зазор SVM — полоса вокруг разделяющей границы, которую алгоритм стремится сделать широкой. Такая постановка учитывает, насколько близко обучающие объекты подходят к границе. Мягкий зазор допускает, что отдельные объекты попадут внутрь полосы или даже на неверную сторону. За нарушения назначается штраф. Параметр C определяет их цену относительно стремления сделать полосу шире. Опорные векторы — обучающие объекты, участвующие в определении границы. Это роль в обучении модели, тогда как эталон выполняет роль образца класса. Термины поэтому не взаимозаменяемы. Когда обучение завершено, можно перестать обсуждать подбор прямой и измерить расстояние до уже готовой границы для любого объекта.

СЛАЙД 11

Геометрический отступ и запас прочности

Геометрический отступ — расстояние до границы со знаком: плюс на правильной стороне и минус на ошибочной. Для проверки правильности снова требуется истинная метка. Обозначим этот отступ буквой γ. Его модуль — неотрицательное расстояние r, доступное и без известной метки. Для линейной модели это запас сохранения текущего ответа: изменение признаков меньшей длины не пересечёт границу. Расстояние выражено в выбранном масштабе и не является вероятностью. Большой запас способен сохранять ошибочный ответ. Разность расстояний до эталонов и геометрический отступ SVM имеют разные определения. Малый запас выделяет решения, которые легко изменить.

СЛАЙД 12

Что такое пограничный объект

Пограничный объект расположен близко к границе: небольшое изменение его признаков может сменить прогноз. Пограничными бывают оба класса, правильные решения и ошибки. Чтобы отбирать такие объекты, после обучения выбирают порог расстояния для дополнительной проверки. Здесь нужно разделить две полосы. Зазор SVM участвует в обучении и выборе границы. Полоса перепроверки нужна для анализа готовых результатов и задаётся отдельным порогом. Этот порог не следует автоматически из параметра C. По расстоянию нельзя узнать правильный класс, зато можно выделить чувствительные к изменению признаков ответы. Теперь определения готовы: применим их последовательно к одной задаче сетевой безопасности.

СЛАЙД 13

Единый пример: норма и SYN-flood

Рассмотрим нормальный трафик и SYN-flood. Обычное TCP-соединение начинается с рукопожатия: клиент отправляет SYN, сервер отвечает SYN-ACK, клиент завершает обмен подтверждением ACK. При SYN-flood множество начатых подключений не завершается. Если сервер хранит их состояние, очередь незавершённых подключений и ресурсы могут оказаться заняты, мешая обычным клиентам. Наша задача — классифицировать окна наблюдения за трафиком: нормальная работа или SYN-flood. При этом большое количество подключений встречается и при легитимной нагрузке, а незавершённость бывает связана с проблемами сети. Поэтому нужен набор измеримых признаков, а не предположение, что всякий рост активности означает атаку.

СЛАЙД 14

Из трафика получаем признаки

Один объект — окно десять секунд к одному IP-адресу и TCP-порту. Первый признак — среднее количество входящих SYN в секунду. Второй — доля начатых попыток без полного рукопожатия за три секунды. Скорость учитывает повторные SYN, а при подсчёте попыток повторы объединяют. Нужны оба направления обмена; окна без SYN исключаем. Последним попыткам окна даём время завершиться, поэтому измерение получается с задержкой. Для расчётов SYN в секунду делим на тысячу, проценты — на сто. Учебная таблица содержит двадцать обучающих окон, поровну двух классов, и восемь специально выбранных проверок. Все значения синтетические. По обучающим окнам теперь выберем два медоида.

СЛАЙД 15

Выбираем два эталона трафика

Эталоном нормального трафика стал объект N05: 600 SYN в секунду и 15 процентов незавершённых попыток. Эталоном SYN-flood стал A06: 1300 SYN в секунду и 65 процентов. В ноутбуке для каждого кандидата проверена сумма расстояний до остальных обучающих объектов своего класса. Названные объекты дают минимумы этих сумм. Так выполнен именно тот алгоритм выбора медоида, который мы разобрали в теории. Числа описывают наши учебные образцы и не являются универсальными порогами атаки для любого сервера. Один и тот же уровень нагрузки у разных сервисов имеет разный смысл. Проверим выбранное правило на конкретном окне T07.

СЛАЙД 16

Окно T07: классификация по эталонам

У T07 скорость 1200 SYN в секунду, незавершённость 16 процентов. Истинный класс в нашей учебной таблице — норма. После масштабирования получаем координаты 1,20 и 0,16. Расстояние до нормального эталона примерно 0,600083, до эталона атаки — 0,500100. Ближе оказался эталон атаки, поэтому правило ошиблось. Для известного нормального класса отступ — чужое расстояние минус своё: 0,500100 минус 0,600083, то есть примерно минус 0,099983. Отрицательный знак согласуется с ошибкой. Высокая легитимная нагрузка иллюстрирует ограничение описания класса одним образцом. Не меняя данные, построим альтернативное правило SVM на той же обучающей выборке.

СЛАЙД 17

Обучаем SVM на той же выборке

В Colab используем SVC из библиотеки scikit-learn — реализацию SVM. Обучаем линейную модель с C, равным единице, на всех двадцати объектах. В коде также зафиксированы точность вычисления и остальные настройки для воспроизводимости. Масштаб признаков и разделение данных остаются прежними. Эталоны не заменяют обучающую выборку и не являются единственными примерами для SVM. В коде норме назначена метка минус один, SYN-flood — плюс один. Одна ячейка обучает модель, следующая получает прогноз и расстояние. Подробные коэффициенты доступны в ноутбуке; для сравнения нам сейчас важнее поведение правила. Поэтому снова подадим T07 с теми же измерениями.

СЛАЙД 18

То же окно T07: результат SVM

Для T07 SVM выбирает нормальный трафик, что совпадает с известной учебной меткой. Числовая оценка f примерно минус 0,248833: в нашей кодировке отрицательный знак выбирает норму. Геометрический отступ γ при этом положительный, около 0,101921, поскольку ответ правильный. Расстояние r равно 0,101921. Таким образом, знак оценки выбирает класс, а знак размеченного отступа показывает правильность. Этот запас относится к изменению масштабированных признаков. Его нельзя напрямую сравнивать с минус 0,099983 у эталонного правила: определения разные. Исправление одной иллюстрации также не доказывает, что SVM всегда лучше. Теперь вычислим те же характеристики для остальных проверочных окон.

СЛАЙД 19

Считаем отступы для восьми окон

В таблице собраны все восемь окон от T01 до T08: истинный класс, прогноз SVM, геометрический отступ со знаком и запас без знака. Для T04 и T05 геометрический отступ отрицателен — здесь модель ошиблась. Для остальных он положителен. Запас r во всех случаях неотрицателен и равен модулю γ, поэтому сам по себе не сообщает, правильный ли ответ. Таблица позволяет проверить вычисления и сравнить положение наблюдений относительно одной готовой границы. Однако специально подобранные синтетические примеры не являются независимым тестом качества детектора. Из этой таблицы выделим малые запасы и разберём значение двух ошибок.

СЛАЙД 20

Пограничные окна и две ошибки

Для демонстрации выбираем порог r меньше 0,10. В перепроверку попадают T03, T04, T05 и T06. Это отдельное правило обработки результатов, а не зазор SVM при обучении. T04 — пропуск атаки: по метке это SYN-flood, а модель ответила «норма». T05 — ложная тревога: нормальный объект назван атакой. Пропуск создаёт риск оставить атаку без внимания, ложная тревога нагружает аналитика и может мешать пользователям при необоснованной реакции. Обе ошибки здесь оказались пограничными, но это не гарантирует выявление всех ошибок на реальном трафике. Значит, полезно передавать специалисту ИБ и прогноз, и отдельный признак пограничности.

СЛАЙД 21

Как использовать результат в ИБ

Вводим два отдельных флага. attack_alert означает прогноз атаки при любом запасе. boundary_review означает малый запас при любом прогнозе. triage — наша учебная функция первичной сортировки. Для входа 900 и 40 она выдаёт норму, первый флаг False, второй True. Здесь False означает «нет», True — «да». Для 1550 и 88 — SYN-flood, True и False: отсутствие пограничности не отменяет сигнал атаки. SOC — команда мониторинга и реагирования информационной безопасности. Аналитик сопоставляет результат с журналами, доступностью сервиса, очередью соединений, потерями и контекстом нагрузки. Наш прототип не выполняет автоматическую блокировку и не внедрён в сеть. Валидация — проверка на отдельно выделенных данных. Для рабочей системы нужны реальные данные, валидация с разделением по времени и оценка пропусков и ложных тревог. Так запас дополняет решение, сохраняя свой исходный смысл.

СЛАЙД 22

Что показал сквозной пример

Сквозной пример связал введённые понятия. Мы выбрали эталоны нормы N05 и атаки A06 по понятному критерию медоида. Одно окно T07 последовательно прошло правило ближайшего эталона и SVM: первое ошиблось, второе дало правильный ответ для известной метки. Затем вычислены отступы всех восьми проверочных объектов. Малый запас выделил T03–T06, включая две известные ошибки. Это помогает объяснять решение и назначать дополнительную проверку. При этом ни эталон, ни отступ не гарантируют правильность классификации или защищённость сервера. Числа получены из учебной таблицы, а определения и методы опираются на опубликованные источники.

СЛАЙД 23

Источники

Основы SVM приведены в статье Кортеса и Вапника, конспекте Stanford CS229 и документации scikit-learn. Выбор медоидов описан у Шуберта и Руссеу. RFC 4987 объясняет SYN-flood и способы противодействия. Работа DeepFool рассматривает геометрию изменения решения; здесь используется линейный случай. CICDDoS2019 указан как возможный материал следующего этапа и в расчётах не использован. Руководство NIST SP 800-94 служит источником общих понятий об обнаружении вторжений и проверке тревог. Полная учебная таблица, расчёты и короткая демонстрация доступны в ноутбуке.

ИСТОЧНИКИ И МАТЕРИАЛЫ

Использованные источники

Ссылки ниже активны. Численные таблицы презентации относятся к авторскому учебному примеру.

01 Support-vector networks

C. Cortes, V. Vapnik. Machine Learning, 1995.

doi.org/10.1007/BF00994018

02 CS229: Support Vector Machines

Stanford University. Конспект лекций.

see.stanford.edu · PDF

03 Faster k-Medoids Clustering: Improving the PAM, CLARA, and CLARANS Algorithms

E. Schubert, P. J. Rousseeuw. 2018; редакция 2019.

arxiv.org/abs/1810.05691

04 RFC 4987. TCP SYN Flooding Attacks and Common Mitigations

W. Eddy. IETF, 2007.

rfc-editor.org · RFC 4987

05 Support Vector Machines — scikit-learn

Официальная документация: линейные SVM, мягкий зазор и параметр C.

scikit-learn.org · документация

06 DeepFool: A Simple and Accurate Method to Fool Deep Neural Networks

S.-M. Moosavi-Dezfooli, A. Fawzi, P. Frossard. CVPR, 2016.

cv-foundation.org · публикация PDF

07 CICDDoS2019

Canadian Institute for Cybersecurity, University of New Brunswick. Страница датасета.

unb.ca/cic · CICDDoS2019

08 NIST SP 800-94. Guide to Intrusion Detection and Prevention Systems (IDPS)

K. Scarfone, P. Mell. NIST, 2007.

csrc.nist.gov · SP 800-94